Descarga de libros de Project Gutenberg: por qué se usa un proxy y cómo funciona

Visualizador de Algoritmos de Ordenamiento · Pestaña «Libros Project Gutenberg + Compresión» · 23 de octubre de 2026

Resumen

La pestaña de Libros busca un título en Project Gutenberg, descarga su texto (.txt) y lo comprime con Huffman al formato propio .algomistico. La búsqueda funcionaba, pero la descarga fallaba porque el navegador bloquea ese tipo de petición (bloqueo CORS). La solución es pasar por un intermediario, llamado proxy, que descarga el libro en lugar de la página y se lo entrega al navegador con el permiso que necesita.

En la versión actual la página prueba varias fuentes en orden y valida lo que recibe. Para que la descarga sea estable también se incluye un proxy propio, el archivo `gutenberg-proxy-worker.js`, que se publica gratis en Cloudflare Workers.

1. El problema: por qué fallaba la descarga

Dos servicios con reglas distintas

La pestaña habla con dos servidores diferentes:

Servicio	Para qué se usa	¿El navegador deja leerlo desde la página?
Gutendex (gutendex.com)	Buscar libros: devuelve títulos, autores y enlaces en formato JSON	Sí
Project Gutenberg (gutenberg.org y su espejo gutenberg.pglaf.org)	Entregar el archivo .txt del libro	No: no autoriza a páginas de otros sitios

Qué es CORS

Por seguridad, el navegador no deja que el JavaScript de una página lea respuestas de otro sitio, a menos que ese sitio lo autorice con un encabezado llamado `Access-Control-Allow-Origin`. A esa regla se le llama CORS. Gutendex envía el encabezado y por eso la

búsqueda funciona. Los servidores de Gutenberg que entregan el texto no lo envían, así que el navegador bloquea la lectura y aparece el mensaje «bloqueo CORS».

No es un error del código de la página: es una regla del navegador. Una página que vive en un solo archivo HTML no puede saltársela. Lo que sí se puede cambiar es por dónde pasa la descarga.

2. La solución: usar un proxy

Un proxy es un servidor intermedio. En lugar de pedirle el libro directamente a Gutenberg, la página se lo pide al proxy. El proxy lo descarga (la regla de CORS solo existe en los navegadores, no en los servidores) y lo devuelve a la página agregando el encabezado de permiso.

Es como pedirle a un amigo con credencial de biblioteca que saque el libro por ti y te lo entregue.

Paso	Qué ocurre
1	El usuario hace clic en un libro de los resultados de la búsqueda.
2	La página le pide al proxy la dirección del libro, por ejemplo `https://gutenberg.pglaf.org/cache/epub/1342/pg1342.txt`.
3	El proxy descarga ese archivo desde Gutenberg.
4	El proxy responde a la página con el texto del libro y el encabezado `Access-Control-Allow-Origin: *`.
5	El navegador ve el permiso y deja que la página lea el libro.
6	La página comprime el libro con Huffman y ofrece el archivo .algomistico para descargar.

3. Cómo funciona la descarga dentro de la página

Al hacer clic en un resultado se ejecuta la función `gbGet`, que sigue estos pasos:

1. Saca el número del libro (por ejemplo 1342) de la dirección que dio Gutendex y arma la dirección del archivo de texto en el espejo oficial de Gutenberg, `gutenberg.pglaf.org`. También prepara la misma dirección en `www.gutenberg.org`.
2. Arma una lista de fuentes y las prueba una por una, en este orden: tu proxy propio (si escribiste uno en el campo «Proxy propio»), la descarga directa desde el espejo y desde gutenberg.org, y por último cinco proxies públicos (cors.eu.org, allorigins, codetabs, corsproxy.io y cors.lol). Mientras avanza muestra un mensaje como «fuente 3 de 7».
3. Cada intento tiene un límite de 30 segundos. Si un proxy se cuelga, se corta y se pasa al siguiente.
4. Revisa lo que llegó. Descarta las respuestas de menos de 500 bytes y las que son una página de error (HTML o JSON), aunque vengan con código 200.
5. Comprueba que el libro esté completo. Los textos de Gutenberg terminan con un cierre estándar que empieza con «End of the Project Gutenberg». Si falta, es probable que el proxy lo haya cortado y se sigue con la siguiente fuente.
6. Si alguna fuente entregó el libro completo, lo comprime y termina. Si ninguna lo entregó completo pero alguna entregó algo, comprime la copia más grande y muestra un aviso ⚠ de que puede estar incompleto. Si todas fallan, muestra un mensaje con el enlace al .txt para descargarlo a mano y subirlo con la opción «.txt local».
7. La dirección de tu proxy propio se guarda en el navegador para no escribirla otra vez.

4. Por qué conviene un proxy propio

Los proxies públicos son servicios gratuitos que mantienen terceros, y para este uso tienen varios problemas:

- **Archivos grandes.** Un libro pesa desde unos cientos de KB hasta varios MB, y muchos proxies públicos cortan o rechazan respuestas de ese tamaño.
- **Gratis solo para desarrollo.** corsproxy.io indica que su plan gratuito está pensado para desarrollo local (localhost) y que los sitios en producción necesitan una clave de pago.
- **Poco estables.** Pueden saturarse, cambiar de formato o desaparecer. En julio de 2026 el proyecto de código abierto OpenIPC reportó que, de ocho proxies públicos probados, solo uno logró entregar un archivo de 250 KB, y que ese también empezaba a rechazar peticiones (error 429) después de unas ocho.
- **Privacidad.** Un proxy público ve qué libros pides.

Con un proxy propio no dependes de terceros, controlas qué se puede descargar y el servicio es estable. Cloudflare Workers tiene un plan gratuito suficiente para uso personal (conviene revisar sus límites vigentes en cloudflare.com).

5. Cómo funciona gutenberg-proxy-worker.js

Un Cloudflare Worker es un programa pequeño que corre en los servidores de Cloudflare y tiene una dirección pública (`https://tu-proxy.tu-usuario.workers.dev`). Este es su funcionamiento:

1. **Preflight.** Algunos navegadores hacen una comprobación previa con una petición de tipo OPTIONS. El Worker responde 204 con los permisos de CORS.
2. **Lee la dirección pedida.** Espera el parámetro `url` (`https://tu-proxy.workers.dev/?url=<dirección del libro>`). Si falta o no es válida, responde error 400.
3. **Seguridad.** Solo acepta direcciones `https` de una lista de dominios permitidos: www.gutenberg.org, gutenberg.org, gutenberg.pglaf.org y aleph.gutenberg.org. Cualquier otra recibe error 403. Así nadie puede usar tu proxy para descargar otros sitios.
4. **Descarga.** Pide el archivo a Gutenberg y sigue las redirecciones (la dirección `ebooks/1342.txt.utf-8` redirige a `cache/epub/1342/pg1342.txt`).
5. **Responde.** Devuelve el contenido con `Access-Control-Allow-Origin: *` y el tipo `text/plain; charset=utf-8`, sin esperar a tener todo el libro en memoria.

6. Cómo ponerlo en marcha

1. Crea una cuenta gratuita en dash.cloudflare.com.
2. Entra a Workers & Pages y crea un Worker nuevo (los nombres de los menús pueden variar un poco).
3. Reemplaza el código de ejemplo con todo el contenido de `gutenberg-proxy-worker.js` y pulsa Deploy.
4. Copia la dirección que te da Cloudflare, por ejemplo `https://mi-proxy.usuario.workers.dev`.
5. En la página, abre la pestaña de Libros, pega esa dirección en el campo «Proxy propio», busca un libro y haz clic en él. La página agrega sola el `/?url=` y recuerda el proxy para la próxima vez.

Para comprobar que el Worker funciona, abre en el navegador `https://mi-proxy.usuario.workers.dev/?url=https://gutenberg.pglaf.org/cache/epub/1342/pg1342.txt`. Debe mostrarse el texto de «Pride and Prejudice».

7. Qué pasa después de la descarga: la compresión

Cuando el libro ya está en la página, el proxy deja de intervenir. La compresión trabaja sobre los bytes del archivo:

1. Cuenta cuántas veces aparece cada byte.
2. Construye el árbol de Huffman: los bytes más frecuentes reciben códigos de bits más cortos.
3. Reemplaza cada byte por su código y guarda el resultado en un archivo `.algomistico`.

El archivo tiene esta estructura: la marca `ALGOMISTICO1`, el tamaño original (4 bytes), la cantidad de símbolos distintos (2 bytes), la tabla de frecuencias (5 bytes por símbolo), un byte con los bits de relleno y, al final, los datos comprimidos. Para descomprimir se reconstruye el mismo árbol a partir de la tabla y se recorren los bits.

8. Alcance y limitaciones

- **Qué se probó.** Con una red simulada se comprobaron ocho escenarios (proxy bloqueado, respuesta con error, libro cortado, proxy colgado, proxy propio, descarga directa, todo fallando y el flujo completo desde la búsqueda) y seis comportamientos del Worker. En las pruebas, el libro descomprimido coincide byte por byte con el descargado.
- **Qué no se probó.** No hubo acceso a los servidores reales de Gutenberg ni a los proxies públicos, así que su disponibilidad actual no está verificada.
- **Proxies públicos.** Pueden fallar en cualquier momento. El proxy propio es la opción estable.
- **Plan B.** Si todo falla, descarga el .txt desde gutenberg.org y súbelo con «.txt local».
- **Uso razonable.** El proxy está pensado para descargas individuales de libros, no para descargas masivas.

Glosario

Término	Significado
CORS	Regla del navegador que decide si una página puede leer respuestas de otro sitio.
Proxy	Servidor intermedio que hace una petición en nombre de otro.

Término	Significado
Cloudflare Worker	Programa pequeño que se ejecuta en los servidores de Cloudflare y responde en una dirección pública.
Gutendex	Servicio gratuito que permite buscar en el catálogo de Project Gutenberg.
Espejo (mirror)	Copia oficial de los archivos en otro servidor, aquí gutenberg.pglaf.org.
Huffman	Método de compresión que da códigos más cortos a los símbolos más frecuentes.